UNMANNED RETAIL DECISION INTELLIGENCE • 契约优先（Contract-First）智能经营平台

# 莱森购 Retail Intelligence Agent

## 五位一体经营工作台 × 确定性规则与数据层 × 七层受控 LangGraph 智能体

CENTRAL THESIS // 中心主旨与三大核心经营追问

**拒绝“只画图不归因”与“大模型算错账”——围绕 ① 哪些门店/区域需关注？ ② 差距来自哪、证据是什么？ ③ 现在做什么、何时复核有效？ 打造零幻觉闭环。**

END-TO-END CLOSED LOOP // 端到端七步经营决策闭环

1. **提出经营问题** 自然语言 / 监控唤醒 → 2. **白名单工具规划** 7 个受控只读/写工具 → 3. **指标/对标/选址** 先聚合后比率·中位数 → 4. **证据校验与重规划** 四值防呆·缺失熔断 → 5. **人工确认任务** Human-in-the-Loop → 6. **下一周期复核** 达标关闭 / 未达标升级

**¥105.4万**
7日营收大盘 (利润21.8万 / 42台设备)

**21店×42天**
长春5区全量流水 + Supabase 4表 Wiki

**7层×7节点**
LangGraph 受控编排 + KV Cache 六铁律

**0 数值幻觉**
白名单数值核验 + S004 缺失数据熔断

五大共享视图：驾驶舱 • 智能审计 • 区域选址 • 行动中心 • 莱财顾问 & 检测台 API Contract v0.1




受控 Agent 诊断抽屉：思考步骤可视化 • 证据锚定 • 人机协同审批卡 TRACEABLE



# 高频无人零售场景下，“看图猜原因、AI 乱算账、建议无复核”是三大核心痛点

覆盖长春 5 大城区（朝阳 / 南关 / 宽城 / 二道 / 绿园）、5 家核心标杆店与 21 家全量门店 × 42 天日经营流水与设备心跳

SCENE 01 // 驾驶舱与风险地图

**全域点位态势感知**

实时掌握 105.4万 营收、 95.2% 设备在线率、42 天日销售斜坡与长春 GIS 风险地图。

SCENE 02 // 异常审计与同城对标

**单店多指标共振归因**

如 **A店/S001** 退款率飙至 7.0% （同城中位数 2.1% ）、订单跌 31% ，需快速定位症结。

SCENE 03 // 区域选址与 ROI 测算

**新商圈投放科学评估**

对比朝阳区（ 86.5分 / 回本 8.4月 ）与南关区（租金缺失不瞎猜），严控选址投资风险。

SCENE 04 // IoT 心跳主动巡检

**无人设备离线秒级响应**

冷柜断网、温控失联或支付掉线时，无需人工盯盘即可触发告警、升级并唤醒审计。

SCENE 05 // 整改派单与周期复核

**经营动作闭环验效**

派发“24h内抽查20笔退款单”任务，并在下一周期自动核验 `refund_rate` 是否达标回落。

PAIN POINT 01 // 传统 BI 报表的局限

## “只给图表，不给归因与缺失保护”

- **聚合抹平斜坡趋势**：只给周期汇总，看不出 `S001` 自 10月6日起连续 3 天渐进式滑坡。
- **规模与效率混为一谈**：销售额下滑未拆解为**订单数 × 客单价**双因子，误把客流波动当客单问题。
- **最危险的“假阴性”**：如 `S004` 退款字段断报（空值率 `33%` ），传统报表直接算作 0 异常，掩盖严重故障。

❌ 症结：有数字无洞察，数据断报时产生致命“假阴性”误导

PAIN POINT 02 // 通用大模型 / TEXT-TO-SQL 的风险

## “口径幻觉、乱算比率与强行归因”

- **比率口径算错**：LLM 自由写 SQL 经常直接 `AVG(daily_ratio)` 平均每日比率，违背“先 SUM 聚合再算比率”铁律。
- **样本不足强行定论**：当同业态可比门店 `< 3 家` 或南关区缺租金数据时，通用 AI 仍会编造回本周期与根因。
- **越权与数值幻觉**：易受 Prompt 注入诱导修改阈值，或在总结中凭空捏造未查询到的财务数字。

❌ 症结：黑盒自由生成不可信、不可复现，业务与财务不敢用

PAIN POINT 03 // 传统问答与工单的断层

## “被动问答聊完即止，无执行复核闭环”

- **被动等待“人找数据”**：凌晨设备心跳中断或连续离线时，若无人主动提问，AI 永远沉默。
- **分析与工单两张皮**：聊天窗口给出“建议核查退款”，但缺负责人角色（ `owner_role` ）、缺 `24h` 时限与证据绑定。
- **缺少下一周期验效**：任务勾掉就算完，没人对比下一周期退款率是否回到同城中位数 `+2pt` 以内。

❌ 症结：停留在“嘴上建议”，无法把诊断转化为真实经营改善

# 核心哲学：确定性引擎做“后厨”算准事实，受控 Agent 做“服务员”编排与表达

A（前端五视图）/ B（确定性数据与规则层）/ C（LangGraph 智能体与 API）基于冻结契约 `API Contract v0.1` 并行解耦协作

ARCHITECTURAL PARADIGM // 四重架构护城河

## 把确定性留给代码，把交互留给 Agent

**1. 标准化后厨（B 层：确定性指标与四值规则引擎）**

先聚合后算比率、`NULLIF` 零保护、按门店中位数算区域 ROI；严格执行 `unavailable → insufficient → possible → none` 判定序，彻底消灭假阴性。

**2. 受控服务员（C 层：7 工具白名单 + 双向防幻觉护栏）**

严禁写 SQL 或改阈值！输出护栏通过 `collectAllowedNumbers` 逐字比对工具证据池，出现任何未授权数字立即熔断回退，保障 **100% 零数值幻觉**。

**3. 高性能上下文（KV Cache 六大铁律 + 三层记忆）**

静态前缀 `deepFreeze` 零插值、Append-Only 消息轨迹、禁滑动窗口截断、采用 SHA-256 持久化摘要压缩，兼顾高缓存命中率与跨轮次指代消解。

**4. 全天候巡检员（IoT 主动监控 + 人机协同复核）**

设备离线 5 分钟自动告警并唤醒 Agent 审计，15 分钟未确认自动升级；经营动作需人工确认并在下一周期复核指标。

| 核心对比维度 | 传统 BI 报表系统 | 传统通用 AI (Text-to-SQL) | 莱森购 Retail Intelligence Agent |
|---|---|---|---|
| 1. 口径与计算准确性 | 静态 SQL 聚合，易掩盖斜坡下滑，无双因子自动拆解 | LLM 自由写 SQL 易平均每日比率、算错口径，结果不可复现 | **Contract-First 确定性计算：先 SUM 再算比率，区域利润/回本取门店中位数，0 算账幻觉** |
| 2. 数据缺失与可比防呆 | 字段断报常显示为 0，造成“无异常”的致命假阴性 | 样本不足或缺成本时仍强行编造回本周期与确定性根因 | **S004 缺失熔断 + 两层逐指标可比准入：少于 3 家返回 `insufficient`，缺租金返回 `null`** |
| 3. 安全边界与防幻觉 | 无自然语言交互，仅支持固定筛选器查询 | 易受 Prompt 注入越权，总结文本常夹带未查询的幻觉数字 | **7 白名单工具 + 双向护栏：拦截 SQL 注入/改阈值，`collectAllowedNumbers` 零幻觉校验** |
| 4. 记忆与上下文工程 | 无上下文记忆，每次筛选互不关联 | 系统提示词插值破坏缓存，用 `slice(-N)` 截断丢失历史 | **KV Cache 六铁律 + 三层记忆：静态前缀冻结、SHA-256 压缩复用、支持“帮它派单”指代消解** |
| 5. 触发方式与执行闭环 | 纯被动看图，无任务派发与效果追踪 | 被动一问一答，聊完即止，无 SLA 升级与复核机制 | **主动监控 Loop + 人机复核闭环：心跳离线唤醒 Agent 审计，人工确认派单并按周期复核关闭/升级** |



差异化总结：不是“给大模型接个数据库”，而是用冻结契约、规则状态机、安全护栏与主动闭环重塑企业级 Agent 工程标准

# 五位一体交互工作台 × 四值规则防呆引擎 × Supabase 结构化知识 Wiki

所有金额与数量先聚合再算比率，每个指标、排名与异常结论均携带 `evidence_ids`、`data_version` 与 `trace_id`

FRONTEND & LOCATION SCORING // 五大共享视图与四维选址模型

## 1. 五页共享同一数据契约 + 区域四维加权 ROI 测算

| ¥1,054,000 | 7.0% vs 2.1% | 86.5分 / 8.4月 |
|---|---|---|
| 7日总销售额（利润 ¥21.8万） | A店/S001 退款率 vs 同城中位数 | 朝阳区评分与回本（南关区 null） |

- **五大核心页面 + 双顾问入口**：① 经营驾驶舱（含 42 天日销售斜坡序列与长春 Leaflet GIS 风险地图） ② 智能审计与同城对标 ③ 区域投放决策 ④ 经营行动中心 ⑤ **“莱财”AI 经营顾问气泡 & Agent 检测工作台**（实时检视规划合同、KV Cache 与 API 健康度）。
- **销售额双因子拆解**：强制将销售额波动拆解为 `order_change_pct`（订单数）与 `aov_change_pct`（客单价），避免把规模波动误判为效率问题。
- **区域四维评分与中位数 ROI 模型**：按 `Score = 0.35×需求 + 0.25×竞争 + 0.25×毛利 − 0.15×成本` 归一化评分；区域月利润与回本周期取区域内门店**中位数**（防止沦为门店数量比较）；南关区缺长租成本时强制返回 `estimatedPaybackMonths = null`。

**前端零私算原则**：React 前端只渲染后端契约返回的数值、单位、证据与状态标签，绝不在前端复制公式或篡改风险等级。

DETERMINISTIC DATA LAYER & WIKI // 规则状态机与三路径数据层

## 2. 四值防呆状态机 + 两层可比准入 + Supabase 4表 Wiki

PRIORITY 01 **unavailable** 有效天<5 或空值>20% → PRIORITY 02 **insufficient** 可比店<3 或仅中1条 → PRIORITY 03 **possible** 命中≥2条且样本充足 → PRIORITY 04 **none** 数据完整且无异常

- **S004 缺失熔断与“两层逐指标可比准入”**：`S004` 自 10月6日起退款字段断报（空值率 `33% > 20%`），单店审计严格触发 `unavailable` 熔断保护；但在同区对标时按**逐指标准入**保留其完整的销售/订单数据，防止朝阳区可比池跌破 `min_peers = 3` 临界值。
- **防误伤单店规则**：当同区域 `≥40%` 门店同步异常且离散度低时，自动标记为**“区域性波动”**，严禁直接归咎于单店店长。
- **三路径无缝切换 + Supabase 4张核心表**：支持 **前端内存夹具 / Python 离线服务（`--offline`）/ Supabase PostgreSQL** 三路径；云端内置 `store_operations_daily`、`region_market_inputs`、`tasks_and_traces` 及 `knowledge_wiki`（统一承载语义规则 `semantic_rule`、处置剧本 `sop_playbook`、商圈档案 `region_profile` 与预留 1536 维向量的历史案例）。

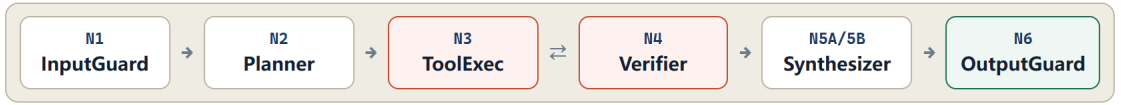
**确定性验证保障**：提供 `python tools/verify_local.py` 与 `npm run validate:contracts` 自动化校验全量指标与契约 Fixture。

# LangGraph 七层状态机 × KV Cache 极致优化 × 三层记忆与双向防幻觉护栏

兼容 OpenAI / Anthropic 双协议，无外部模型密钥或断网时自动无缝切换至 100% 确定性规划与总结回退引擎

7-LAYER ARCHITECTURE & STATEGRAPH // 七层解耦与有界重规划

## 1. 七层架构 + 7节点受控图 (含 Bounded Re-plan)




| | | |
|---|---|---|
| L1 定义层 | definition.js | 冻结身份原则、7工具契约、全局 `AgentStateAnnotation` |
| L2 模式层 | pattern.js | 受控 Plan-and-Execute 状态图拓扑与条件路由规则 |
| L3 组件层 | components/* | 意图解析、工具适配、`contextBuilder`、`memoryManager` |
| L4 机制层 | mechanisms.js | 发现高风险且未对标时触发 **单次有界重规划 (Bounded Re-plan)** |
| L5 安全层 | safety.js | 防注入拦截、Schema 归一化、`collectAllowedNumbers` 防幻觉 |
| L6 编排层 | orchestrator.js | 组装编译官方 `StateGraph`，挂载 Checkpointer 与 Store |
| L7 工程层 | api.js & traceLogger | 统一 `/api/v1/*` 网关、全链路 Trace 回放与契约自检 |

只读: get_dashboard | 只读: run_audit | 只读: compare_regions | 只读: estimate_region_roi | 受控写: create_task | 受控写: verify_task | 受控写: write_report

KV CACHE, 3-TIER MEMORY & GUARDRAILS // 上下文工程与安全防线

## 2. KV Cache 六大铁律 + 三层记忆 + 双向防幻觉护栏

- **严格遵守《上下文与 KV Cache 约束》六大铁律**：
  ① `STATIC_SYSTEM_MESSAGE` 与固定顺序 7 工具 Schema `deepFreeze` 字节级锁定，零运行时变量插值；
  ② 动态信息（`query`、窗口、记忆、工具结果）一律 Append-Only 追加至消息尾部；
  ③ 严格使用 `system / user / assistant / tool` 四角色与 `tool_call_id`；
  ④ **严禁滑动窗口** `.slice(-N)` **截断历史**！超阈值时调用 `compactMessagesIfNeeded` 生成确定性 SHA-256 哈希摘要并持久化逐字节复用，实时统计 `cached_tokens` 命中率。
- **LangGraph 官方三层记忆体系与多轮指代消解**：
  融合 **短期工作记忆**（单轮图状态）+ **会话线程记忆**（`MemorySaver` + 焦点实体槽位 `lastDeviceId / lastRegionIds / lastTaskId`，支持第 2 轮说“**那帮它创建一个整改任务**”自动锁定上轮门店）+ **跨会话长期记忆**（`InMemoryStore` 持久化门店风险档案与历史任务）。
- **双向安全护栏与业务脱敏铁律**：
  • **输入护栏**：拦截 `DROP TABLE`、修改阈值、绕过白名单等越权注入指令，降级在只读沙箱内完成合法查询；
  • **输出护栏**：自动提取证据池合法数字白名单（`hasHallucinatedNumbers`），发现未授权数字立即用确定性模板回退；同时**严禁向用户暴露内部函数名/变量名**，输出 Antigravity 风格业务化思考步骤（`thinkingSteps`）。

**自动化回归脚本**：`npm run test:agent` 全量验证 7 层架构、规划合同、KV Cache 前缀字节恒等与防幻觉门禁。



核心代码映射：src/agent/{definition,pattern,mechanisms,safety,orchestrator}.js · src/agent/components/{contextBuilder,memoryManager,llmClient}.js

# 从“被动问答”到“人机协同派单复核”与“设备心跳主动唤醒审计”双闭环

不仅能回答用户提问，更能在设备异常时主动唤醒 Agent 补充审计证据，并追踪每一次整改动作在下一周期的真实指标改善

HUMAN-IN-THE-LOOP ACTION CENTER // 经营行动中心与周期复核

## 1. 待确认决策提案 → 6态任务流转 → 下一周期指标复核




- **人机协同审批门禁（`decisionProposal`）**：高风险经营动作（门店整改、新区域投放）严禁由 LLM 自动执行，必须先生成包含 `decisionBasis`（同行分位证据）、`expectedImpact`（预期收益/回本周期）、`ownerRole`（区域经理）与 `dueHours`（24h）的审批卡片，由人工点击“确认采纳方案”后才触发 `create_task` 幂等落库。
- **量化指标驱动的周期复核（`verify_task`）**：每张行动卡绑定明确的复核指标（如 `verify_metric: "refund_rate"`，目标“回落至同类中位数 +2 个百分点以内”）。
- **自动关闭与升级分流**：进入下一观察窗口后，系统自动对比复核指标——若达标（`improved-task`）则保存复核证据并流转为 `closed`；若未改善或命中 3 条红线（`unresolved-task`）则自动升级为 `escalated` 提级督办。

**核心价值**：消灭“只提建议不看结果”的假闭环，让每一条 AI 建议都有责任人、截止时限与下一周期的量化验收单。

PROACTIVE IOT MONITOR LOOP // 事件驱动主动巡检与告警升级

## 2. 设备心跳监控 → 自动唤醒 Agent 审计 → 多渠道 SLA 升级




- **独立于问答链路的后台事件引擎**：通过 `/api/v1/agent/monitor/heartbeat` 持续接收设备心跳，连续 **2 分钟**无心跳即判定离线，并按 `device-offline:{deviceId}` 唯一键幂等去重，防止告警风暴。
- **SLA 阶梯升级与自动唤醒 Agent 审计**：离线满 **5 分钟**进入 `alerted` 阶段，发送首条负责人通知并**异步调用 Agent 审计链路**，将门店近期经营异常与证据自动挂载至告警单（`agentSummary` / `agentFindings` / `agentTraceId`）；满 **15 分钟**仍未确认则自动流转为 `escalated` 发送升级督办通知。
- **多渠道通知适配与断点持久化**：内置站内通知列表、外部 **Webhook JSON 推送**（`AGENT_NOTIFY_WEBHOOK_URL`）以及 **QQ 邮箱 SSL SMTP（465端口）**异步邮件告警；全量状态实时持久化至 `tmp/agent-monitor-state.json`，服务重启不丢状态。

**自动化回归脚本**：`npm run test:monitor-loop` 完整覆盖去重、5m通知、15m升级、确认、恢复结案与重启恢复。

# 三阶段演进蓝图：从模块化单体闭环走向多模态感知与自进化零售大脑

当前架构已预留完整的共享类型契约、外部数据适配器接口与 PostgreSQL `pgvector(1536)` 向量检索扩展能力

PHASE 01 // 生产级底座与实时物联

## 真实数仓、边缘网关与多租户安全

MQTT 边缘网关 | OIDC / RBAC 鉴权 | 多租户 RLS 隔离

- **真实 IoT 与实时数仓接入**：将模拟心跳升级为鉴权后的边缘设备网关（智能冷柜温控、门锁、支付终端流式事件），对接企业 ERP/POS 准实时数仓。
- **生产级多租户与行级权限**：基于 OIDC/OAuth2 注入 `tenant_id`、角色与区域权限，结合 PostgreSQL RLS 与 Redis 分布式幂等锁保障高并发安全。
- **企业级 IM 深度协同**：Webhook 适配层直接对接企业微信 / 飞书交互卡片，支持移动端一键确认告警与审批任务。

🎯 里程碑：从单机/云端原型平滑升级为生产级多租户 SaaS 平台

PHASE 02 // 多模态视觉与全域协同

## 视觉陈列巡检 + 供应链/会员全域扩展

多模态视觉巡检 | 智能补货与动销 | 会员与人效域

- **多模态视觉大模型巡检**：接入货柜摄像头与门店监控快照，自动识别核心 SKU 排面空缺、价签错放、设备污损与异常拿取行为，生成视觉证据 ID。
- **库存、会员、营销与人效域扩展**：在现有经营契约上扩展 SKU 级库存周转、临期损耗、会员复购率与运维补货员排班人效指标。
- **外部实时地理与客流 API**：接入真实商圈客流热力、天气与竞品动态数据，驱动区域选址模型动态校准。

🎯 里程碑：实现“经营财务数据 + IoT 传感 + 视觉图像 + 供应链”四维融合

PHASE 03 // 向量记忆与自进化大脑

## pgvector 案例检索 + 策略自进化网络

pgvector 混合检索 | 策略强化自优化 | 多 Agent 协同

- **激活 `knowledge_wiki` 向量混合检索**：启用已预留的 `embedding vector(1536)` 列，将每次结案的异常特征、处置动作与复核结果向量化入库，实现“相似历史疑难案例”毫秒级召回。
- **复核效果驱动的闭环自优化**：统计不同区域、不同 SOP 动作在 `verify_task` 阶段的真实达标率与利润挽回额，动态优化风险排序权重与推荐策略。
- **按需演进多 Agent 专职协同**：在审计契约稳定后，拆分为审计 Agent、选址 Agent、供应链补货 Agent 与巡检督办 Agent 协同网络。

🎯 里程碑：沉淀企业专属经营记忆，成为越用越准的自进化无人零售大脑

**莱森购 Retail Intelligence Agent • 让每一次无人零售经营决策都有据可查、有果必验**

Contract-First 确定性底座 × 四值防呆规则引擎 × LangGraph 七层受控编排 × KV Cache 六铁律 × 主动监控与人工复核双闭环

THANK YOU // Q&A

npm run dev · PORT=4173 npm start